

13 **알**고보면 **쓸**모있는 **신**기한 **기**계학습





강의 내용

Contents of Lecture

기간	내용	과제
01주차	오리엔테이션 lpython - 파이썬에 날개를 달자	실습 과제 <u>(채점 X)</u>
02주차	Numpy 소개	실습 과제
03주차	Pandas로 데이터 가공하기	실습 과제
04주차	Matplotlib를 활용한 시각화	실습 과제
05주차	탐색적 데이터 분석	실습 과제
06주차	데이터의 표본분포	실습 과제
07주차	통계적 실험과 유의성 검정	실습 과제
08주차	중간고사 - 오프라인 오픈북으로 진행	기말 프로젝트 상세 공지

기간	내용	과제
09주차	인공지능 & 회귀/예측	실습 과제
10주차	회귀와 예측 / 분류	실습 과제
11주차	분류 및 머신러닝 기초	
12주차	통계적 머신러닝	실습 과제
13주차	비지도 학습	실습 과제
14주차	알고보면 쓸모있는 신기한 기계학습	프로젝트 레포트 제출
15주차	[기말고사] Team별 프로젝트 결과 발표	<u>종강~!</u>

알쓸신기 1부

- 1) SQL (SQL VS NoSQL)
- 2) DB (Row Oriented VS Column Oriented)
- 3) File Extension (Row Based VS Column Based)
- 4) Memory Optimization






SQL

Structured Query Language

- 관계형 데이터베이스 관리 시스템(RDBMS)의 데이터를 관리하기 위해 설계된 특수 목적의 프로그래밍 언어
 - 자료의 검색과 관리
 - 데이터베이스 스키마 생성과 수정
 - 데이터베이스 객체 접근 조정 관리
- 많은 수의 데이터베이스 관련 프로그램들이 SQL을 표준으로 채택하고 있다.





Database 종류

Kinds of DB

- Relational DBMS
- Key-value stores
- Document stores
- Time Series DBMS
- Graph DBMS
- Object oriented DBMS
- Search engines
- RDF stores
- Wide column stores
- Multivalue DBMS
- Native XML DBMS
- Spatial DBMS
- Event Stores
- Content stores
- Navigational DBMS





SQL 구문

Structured Query Language

- 데이터 정의 언어 (DDL : Data Definition Language)
- 데이터 조작 언어 (DML : Data Manipulation Language)
- 데이터 제어 언어 (DCL : Data Control Language)





SQL 구문

Structured Query Language

데이터 정의 언어 (DDL : Data Definition Language)

- CREATE (데이터베이스 개체 (테이블, 인덱스, 제약조건 등)의 정의)
- DROP (데이터베이스 개체 삭제)
- ALTER (데이터베이스 개체 정의 변경)

```
CREATE TABLE My_table(  
  my_field1 INT,  
  my_field2 VARCHAR(50),  
  my_field3 DATE NOT NULL,  
  PRIMARY KEY (my_field1, my_field2)  
);
```

- **ALTER** 는 다양한 방법으로 현존하는 객체의 구조를 변경한다. 예를 들어, 현재의 테이블에 컬럼을 추가하거나 제한을 추가한다. 예를 들면:

```
ALTER TABLE My_table ADD my_field4 NUMBER(3) NOT NULL;
```

- **TRUNCATE** 는 테이블에서 모든 데이터를 빠르게 삭제한다. 내부 테이블의 데이터를 삭제하는 것이지, 테이블 자체를 삭제하는 것은 아니다. 이 과정은 보통 순차적인 **COMMIT** 연산을 내포한다. 예를 들어, 이것은 롤백되지 않는다. (DELETE와는 달리 이후 롤백을 위한 로그가 기록되지 않는다.).

```
TRUNCATE TABLE My_table;
```

- **DROP** 은 데이터베이스에서 객체를 삭제하며, 보통 **롤백**을 통해 복원할 수 없다. 예를 들어:

```
DROP TABLE My_table;
```



SQL 구문

Structured Query Language

데이터 조작 언어 (DML : Data Manipulation Language)

- INSERT INTO (행 데이터 또는 테이블 데이터의 삽입)
- UPDATE ~ SET (표 업데이트)
- DELETE FROM (테이블에서 특정 행 삭제)
- SELECT ~ FROM ~ WHERE (테이블 데이터의 검색 결과 집합의 취득)





SQL 구문

Structured Query Language

데이터 제어 언어 (DCL : Data Control Language)

- GRANT (특정 데이터베이스 사용자에게 특정 작업을 수행 권한을 부여)
- REVOKE (특정 데이터베이스 이용자로부터 이미 준 권한을 박탈 함.)
- SET TRANSACTION (트랜잭션 모드 설정 (동시 트랜잭션 격리 수준 (ISOLATION MODE) 등))
- BEGIN (트랜잭션 시작)
- COMMIT (트랜잭션의 실행)
- ROLLBACK (트랜잭션 취소)
- SAVEPOINT (무작위로 롤백 지점을 설정)
- LOCK (TABLE 등의 자원을 차지)






SQL VS NoSQL

Structured Query Language VS Non Structured Query Language

NoSQL

- 전통적인 관계형 데이터베이스 보다 덜 제한적인 일관성 모델을 이용하는 데이터의 저장 및 검색을 위한 매커니즘을 제공
- 디자인의 단순화, 수평적 확장성, 세세한 통제를 포함
- 단순 검색 및 추가 작업을 위한 매우 최적화된 키 값 저장 공간으로, 레이턴시와 스루풋과 관련하여 상당한 성능 이익을 내는 것이 목적
- 빅데이터와 실시간 웹 애플리케이션의 상업적 이용에 널리 쓰임

NoSQL DATABASE TYPES






SQL VS NoSQL

Structured Query Language VS Non Structured Query Language

NoSQL의 종류

- 와이드 컬럼 스토어: H베이스, 아큐물로, 카산드라
- 도큐먼트: 몽고DB, 카우치베이스
- 키 값: 다이내모DB[5], 리악, 레디스, 캐시, 프로젝트 볼드모트
- 그래프: Neo4J, AgensGraph, 알레그로그래프, 버투오소





SQL VS NoSQL

Structured Query Language VS Non Structured Query Language

NoSQL 성능등급표 by 벤 스코필드

벤 스코필드는 여러 유형의 NoSQL 데이터베이스의 등급을 다음과 같이 평가했다:^[17]

데이터 모델 ◆	성능 ◆	확장성 ◆	유연성 ◆	복잡성 ◆	기능 ◆
키-값 스토어	높음	높음	높음	없음	가변적 (없음)
컬럼 지향 스토어	높음	높음	준수	낮음	최소
도큐먼트 지향 스토어	높음	가변적 (높음)	높음	낮음	가변적 (낮음)
그래프 데이터베이스	가변적	가변적	높음	높음	그래프 이론
관계형 데이터베이스	가변적	가변적	낮음	준수	관계대수



SQL VS NoSQL

Structured Query Language VS Non Structured Query Language

Database Engine Ranking

398 systems in ranking, June 2022

Rank			DBMS	Database Model	Score		
Jun 2022	May 2022	Jun 2021			Jun 2022	May 2022	Jun 2021
1.	1.	1.	Oracle +	Relational, Multi-model	1287.74	+24.92	+16.80
2.	2.	2.	MySQL +	Relational, Multi-model	1189.21	-12.89	-38.65
3.	3.	3.	Microsoft SQL Server +	Relational, Multi-model	933.83	-7.37	-57.25
4.	4.	4.	PostgreSQL +	Relational, Multi-model	620.84	+5.55	+52.32
5.	5.	5.	MongoDB +	Document, Multi-model	480.73	+2.49	-7.49
6.	6.	7.	Redis +	Key-value, Multi-model	175.31	-3.71	+10.06
7.	7.	6.	IBM Db2	Relational, Multi-model	159.19	-1.14	-7.85
8.	8.	8.	Elasticsearch	Search engine, Multi-model	156.00	-1.70	+1.29
9.	9.	10.	Microsoft Access	Relational	141.82	-1.62	+26.88
10.	10.	9.	SQLite +	Relational	135.44	+0.70	+4.90
11.	11.	11.	Cassandra +	Wide column	115.45	-2.56	+1.34
12.	12.	12.	MariaDB +	Relational, Multi-model	111.58	+0.45	+14.79
13.	14.	26.	Snowflake +	Relational	96.42	+2.91	+61.67
14.	13.	13.	Splunk	Search engine	95.56	-0.79	+5.30
15.	15.	15.	Microsoft Azure SQL Database	Relational, Multi-model	86.01	+0.68	+11.22
16.	16.	16.	Amazon DynamoDB +	Multi-model	83.88	-0.58	+10.12
17.	17.	14.	Hive +	Relational	81.58	-0.03	+1.89
18.	18.	17.	Teradata +	Relational, Multi-model	70.41	+2.02	+1.07
19.	19.	18.	Neo4j +	Graph	59.53	-0.61	+3.78
20.	20.	20.	Solr	Search engine, Multi-model	56.61	-0.64	+4.52
21.	21.	19.	SAP HANA +	Relational, Multi-model	54.53	-0.56	+0.42
22.	22.	21.	FileMaker	Relational	51.58	-0.69	+2.45
23.	23.	24.	Google BigQuery +	Relational	49.07	+0.46	+9.44
24.	24.		Databricks	Multi-model	48.12	+0.27	
25.	25.	22.	SAP Adaptive Server	Relational, Multi-model	46.67	-1.11	-2.32

[db ranking link](#)

Rank	Name	Market Cap	Price	Today	Price (30 days)	
104	Equinor EQNR	\$122.44 B	\$37.88	2.19%		Norway
105	American Tower AMT	\$121.45 B	\$266.15	0.45%		USA
106	Lockheed Martin LMT	\$121.42 B	\$456.30	2.91%		USA
107	Caterpillar CAT	\$121.12 B	\$227.10	1.55%		USA
108	Anthem ANTM	\$120.64 B	\$500.41	0.60%		USA
109	SAP SAP	\$120.30 B	\$101.99	1.12%		Germany
110	Unilever UL	\$119.51 B	\$46.75	0.09%		UK
111	Ping An Insurance 601318.SS	\$117.74 B	\$6.62	0.25%		China
112	Volkswagen VOW3.DE	\$117.64 B	\$168.82	0.59%		Germany
113	Intuit INTU	\$117.52 B	\$416.65	1.88%		USA
114	S&P Global SPGI	\$117.08 B	\$344.46	1.72%		USA

<https://companiesmarketcap.com/page/2/>





SQL VS NoSQL

Structured Query Language VS Non Structured Query Language



학술 · 예술 및 인류복지증진에
공헌한 인사들을 위한 삼성호암상



2022 수상자

역대 수상자

홈 > 수상자 > 2022 수상자 > 공유하기 > Print

2022 수상자



공학상

차상균 | 서울대 교수, 전기 및 컴퓨터공학

학력 및 경력

1958	부산 출생	2002 ~ 2005	미국 Transact In Memory社 설립
1980	서울대 전기공학 학사	2014 ~ 2019	서울대 빅데이터연구원 원장
1982	서울대 제어계측공학 석사	2020 ~ 현재	서울대 데이터사이언스대학원 원장
1991	미국 스탠퍼드대 전기공학 박사		
1992 ~ 현재	서울대 교수		

수상업적

차상균 박사는 인메모리 데이터베이스 플랫폼인 *HANA를 세계 최초로 개발하여 대용량 메모리 기반 서버 시스템의 시대를 연 세계적인 전문가이다. HANA 플랫폼은 상용화를 통해 빅데이터 분야를 선도하며 현재 구글, 아마존, 메타, 인텔, HP 등 유수의 글로벌 기업에서 사용되고 있다.

기존 대용량 데이터 시스템은 처리 속도가 느린 하드디스크에 데이터를 저장하기 때문에 빠른 연산과 다양한 유형의 데이터 분석이 어려웠다. 차 박사는 이를 해결하기 위해 고가이지만 처리 속도가 빠른 메모리인 *D램을 기존 시스템 대비 수십 배 큰 용량으로 사용하는 아이디어를 고안하였다. 그리고 중요도가 높고 자주 접근되는 데이터를 선택, 저장하는 방식 등을 이용하여 실제 대용량 메모리 시스템을 구현함으로써 고속의 실시간 빅데이터 연산처리가 가능함을 보였다.

차 박사는 이러한 혁신적 아이디어를 바탕으로 2002년 실리콘밸리에서 Transact In Memory(TIM)社를 창업하였다. TIM社는 2005년 독일 SAP社에 전략적으로 합병되었으며, 이후 그는 인메모리 데이터베이스 솔루션인 'SAP HANA'의 연구 개발과 전사적 사업화를 공동 지휘하였다. 현재 삼성전자, 월마트 등 전 세계 17,000여 개 이상의 기업이 'SAP HANA'를 사용하고 있다. 또한, 차 박사가 개척한 대용량 메모리 컴퓨팅 시장은 현재의 클라우드 컴퓨팅 시장으로 발전하였으며, 국내 메모리 산업의 발전에도 기여하였다.

글로벌 무대에서 창업과 비즈니스 경험을 겸비한 연구자이자 기업인인 차 박사는 서울대 데이터 사이언스대학원 설립을 주도하였고 현재 당 대학원 원장으로서 혁신적인 아이디어와 도전정신을 보유한 소프트웨어 인재 양성에도 많은 기여를 하고 있다.

*HANA : 한글의 하나를 의미하고, 데이터베이스와 처리장치를 하나로 합친 의미

*D램 : 시간에 따라 정보가 소멸되기 때문에 주기적으로 재생을 시켜야하는 대용량 임시기억장치로 컴퓨터의 주 메모리로 사용됨

http://www.hoamfoundation.org/kor/award/thisyear_view.asp?idx=492



Row Oriented DB VS Column Oriented DB


Row Oriented DB

Row-Oriented DBMS는 데이터를 어떻게 저장할까?

row0 header	column0 value	column1 value	column2 value	column3 value
row1 header	column0 value	column1 value	column2 value	column3 value
row2 header	column0 value	column1 value	column2 value	column3 value

- 주로 Row-Value 데이터를 연속적으로 저장한다.

실제로 테이블의 데이터파일 모습은?



- 일렬로 저장된 모습을 확인할 수 있다.



- Row-Value의 오프셋은 Value의 자료구조에 의존적이다.
 - 32bit의 Integer, 64bit의 Integer, String 등 자료구조의 크기의 총 합산 크기에 따라 오프셋을 결정한다.

Row Oriented DB 장단점

Row-Oriented를 정리하면

- 장점
 - 하나의 Row 데이터를 추가/삭제할때 하나의 페이지만 사용하기에 좋다.
 - 하나의 Row의 대부분의 컬럼을 읽어야 하거나 변경하는 경우 하나의 Read/Write로 가능하다.
- 단점
 - 모든 Row를 읽는 경우 불필요한 Column값을 다 읽어야 한다.
 - Page의 사용하지 않는 공간까지 읽어야 한다.



Row Oriented DB VS Column Oriented DB

Column Oriented DB

Column Oriented DBMS란?

- Row 형으로 저장하는 대신 Column 으로 저장하는 방식이다.
- 모든 Column 들은 개별적으로 다뤄지며 Column 별로 연속적으로 저장된다.
- Column 별로 데이터가 저장되기때문에 압축에도 높은 효율을 얻을 수 있다.

Row Oriented vs Column Oriented

Row Oriented Database				Table of Data				Column Oriented Database			
date	price	size		date	price	size		date	price	size	
2011-01-20	10.1	10		2011-01-20	10.1	10		2011-01-20	10.1	10	
2011-01-21	10.3	20		2011-01-21	10.3	20		2011-01-21	10.3	20	
2011-01-22	10.5	40		2011-01-22	10.5	40		2011-01-22	10.5	40	
2011-01-23	10.4	5		2011-01-23	10.4	5		2011-01-23	10.4	5	
2011-01-24	11.2	55		2011-01-24	11.2	55		2011-01-24	11.2	55	
2011-01-25	11.4	66		2011-01-25	11.4	66		2011-01-25	11.4	66	
...	...	...		...	...	...		...	...	...	
2013-03-31	17.3	100		2013-03-31	17.3	100		2013-03-31	17.3	100	

- 우리가 평균 가격을 알고 싶다면?
 - Row Oriented 는 모든 Row를 조회해야만 결과를 얻을 수 있다.
 - 하지만 Column Oriented 는 Price 컬럼만 조회해도 결과를 얻을 수 있다.

Column Oriented DB 장단점

항상 Column Oriented가 좋을까?


- 다수의 컬럼을 조회하는 상황이라면 쓸모가 없어보인다.
- 오히려 결과를 합치는 작업 비용이 더 커져서 느릴 경우가 발생할 거 같다.



Column Oriented DB의 대표: Clickhouse DB

Clickhouse DB : Yandex가 자체 개발한 DB

(국내에서 러시아의 Naver라 불리는 회사, 러시아 서치엔진 점유율 2위, [점유율 참조 링크](#))



- ClickHouse®는 온라인 쿼리 분석 처리(OLAP:online analytical processing of queries)를 위한 열 지향 (column-oriented) 데이터베이스 관리 시스템 (DBMS) (<https://clickhouse.tech/docs/en/> 참조)
- Yandex Metrica, 현재, 글로벌 3위 웹 분석 플랫폼의 초기 개발을 위해서 만들어진 DB (<https://clickhouse.tech/docs/en/introduction/history/> 참조)
- Column-oriented는 OLAP 시나리오에 더 적합하며, 대부분의 쿼리를 처리 할 때 최소 100 배 더 빠르다.

장점	단점
진정한 컬럼 지향 데이터베이스 관리 시스템	transaction에서 충분히 자격을 갖추진 못함
데이터 압축	빠른 속도와 짧은 지연 시간으로 이미 삽입 된 데이터를 수정하거나 삭제할 수 있는 능력 부재
데이터의 디스크 스토리지	* GDPR 준수를 위해 데이터 정리 혹은 수정시 사용할 수 있는 일괄 삭제 및 업데이트 기능이 있음
다중 코어에서 병렬 처리	회소 색인은 ClickHouse가 Key로 단일 행을 검색하는 포인트 쿼리에 효율적이지 않음
여러 서버의 분산 처리	
SQL 지원	
벡터 계산 엔진	
실시간 데이터 업데이트	
기본 색인	
보조 인덱스	
온라인 쿼리에 적합	
근사 계산 지원	
적응 형 조인 알고리즘	
데이터 복제 및 데이터 무결성 지원	
역할 기반 액세스 제어	



Clickhouse 속도

See also: [performance-comparison of Clado-Isove on various hardware](#)

<https://clickhouse.tech/benchmark/dbms/>



Column Oriented DB의 대표: Clickhouse DB

https://db-engines.com/en/ranking_trend

Clickhouse 인지도


[Ranking ClickHouse > Trend](#)

DB-Engines Ranking - Trend of ClickHouse Popularity

The DB-Engines Ranking ranks database management systems according to their popularity.

This is a partial trend diagram of the [complete ranking](#) showing only ClickHouse.

Read more about the [method](#) of calculating the scores.




[Ranking > Trend](#)

DB-Engines Ranking - Trend Popularity

The DB-Engines Ranking ranks database management systems according to their popularity.

Read more about the [method](#) of calculating the scores.



[RSS](#) [RSS Feed](#)

Rank	Trend	System	Score	Change
1		Oracle	1880	+27
2		MySQL	1342	+47
3		SQL Server	1278	+40
4		PostgreSQL	174	-3
5		MS Access	161	-8
6		DB2	155	-4

[ranking table](#)
June 2022

Column Oriented DB의 대표: Clickhouse DB

Clickhouse 인지도

ClickhouseDB는 현재 Tesla, Uber, Tencent, Kakao Corp, Alibaba cloud, eBay, Bloomberg에서도 활용중으로 알려져있음

 kakaocorp	Internet company	—	—	—	if(kakao)2020 conference
 ООО «МПЗ Богородский»	Agriculture	—	—	—	Article in Russian, November 2020
 Tesla	Electric vehicle and clean energy company	—	—	—	Vacancy description, March 2021





Column Oriented DB의 대표 in AWS



Amazon Redshift

31위



cassandra

11위



26위

Amazon Redshift

Amazon Redshift는 페타바이트 규모의 완전관리형 열 기반 데이터 웨어하우스입니다. Amazon Redshift에서는 기존의 비즈니스 인텔리전스 도구를 사용하여 비용 효율적으로 간편하게 모든 데이터를 분석할 수 있습니다. Amazon Redshift는 대용량 병렬 처리와 열 기반 데이터 스토리지, 그리고 매우 효율적인 데이터 압축 인코딩 방식을 조합하여 스토리지 효율성과 쿼리 성능 최적화를 구현하였습니다.

[Amazon Redshift에 대해 자세히 알아보기 »](#)

Amazon EC2 또는 Amazon EMR의 열 기반 데이터베이스

개발자는 [Amazon EC2](#) 및 [Amazon EMR](#)에 원하는 열 지향 데이터베이스를 설치할 수 있습니다. 이를 통해 개발자는 다양한 표준 열 기반 데이터베이스 엔진에 액세스하는 동안 인프라 공급 마찰을 방지할 수 있습니다.

Apache Cassandra

Cassandra는 수많은 범용 서버에서 대량의 데이터를 처리하도록 설계된 오픈 소스의 열 지향 데이터베이스입니다. 관계형 데이터베이스의 테이블과 달리 동일한 테이블(열 패밀리)의 다른 행들이 동일한 열 세트를 공유할 필요가 없습니다.

다중 리전 Cassandra 구성을 참조하고 [Vidora](#)의 전 세계에 분산되어 있고 지연 시간이 짧은 [AI](#)를 살펴보세요.

Cassandra 워크로드를 실행할 때 EBS 사용을 고려하십시오([CrowdStrike가 EBS를 통해 저렴한 고밀도 Cassandra 클러스터를 실행하는 방법 알아보기](#)). Cassandra 사용 및 AWS에서의 Cassandra 실행에 관한 자세한 내용은 [Apache Cassandra on AWS](#) 백서를 참조하고 [AWS Marketplace](#)로 이동하기 »



Apache HBase

[Apache HBase](#)는 오픈 소스, 열 지향의 분산 NoSQL 데이터베이스입니다. HBase는 [Apache Hadoop](#) 프레임워크 상에서 실행됩니다. HBase는 열 기반 압축 및 스토리지를 사용하여 대량의 스파스 데이터를 저장할 수 있는 효율적이고 내결함성을 갖춘 방식을 제공합니다.

HBase를 [Amazon Elastic Cloud Compute](#) (Amazon EC2)에 배포하고 직접 관리하거나 Apache Hbase를 [Amazon Elastic MapReduce](#) (Amazon EMR)상에서 관리형 서비스로 활용할 수 있습니다. [EMR 개발자 안내서](#) 및 [AWS 빅 데이터 블로그의 게시물](#) »을 읽고 자세한 내용을 알아보십시오.



Column Oriented DB의 대표 in Azure



Azure Cosmos DB

27위



Azure Table Storage

73위





Column Oriented DB의 대표 in GCP (Google Cloud Platform)



Google
BigQuery

23위



Cloud
Bigtable

86위



Column Oriented DB의 대표

Top 10 Columnar Databases ⓘ

Amazon Redshift | Snowflake | Hbase | Vertica | BigQuery | ClickHouse | Druid | Apache Kudu | MariaDB | Apache Parquet

<https://www.g2.com/categories/columnar-databases>

Row Oriented File VS Column Oriented File

비교 기준


Logical table

	col1	col2	col3
row1	1	2	3
row2	4	5	6
row3	7	8	9
row4	10	11	12

Row-oriented layout (SequenceFile)



Column-oriented layout (RCFile)



Row Oriented File VS Column Oriented File

유명한 File Format 과 Parquet 비교

Spark Format Showdown		File Format		
		<u>CSV</u>	<u>JSON</u>	<u>Parquet</u>
A t t r i b u t e	Columnar	No	No	Yes
	Compressable	Yes	Yes	Yes
	Splittable	Yes*	Yes**	Yes
	Human Readable	Yes	Yes	No
	Nestable	No	Yes	Yes
	Complex Data Structures	No	Yes	Yes
	Default Schema: Named columns	Manual	Automatic (full read)	Automatic (instant)
	Default Schema: Data Types	Manual (full read)	Automatic (full read)	Automatic (instant)



Row Oriented File VS Column Oriented File

Bigdata File Format 비교

BIG DATA FORMATS COMPARISON

	Avro	Parquet	ORC
Schema Evolution Support			
Compression			
Splitability			
Most Compatible Platforms	Kafka, Druid	Impala, Arrow Drill, Spark	Hive, Presto
Row or Column	Row	Column	Column
Read or Write	Write	Read	Read

Source: Nexla analysis, April 2018





Memory / Disk Optimization

- Dataframe 메모리 최적화
 - Data Type 인식 및 메모리 최소화 진행
 - float64 -> float32
 - int64 -> int8,16,32
 - object -> category
- CSV을 GZIP으로 압축하기
 - CSV를 꼭 사용해야한다면, 압축해서 저장 및 로딩
- Parquet 활용하기
 - 속도 최소 / 용량 최소 / 메모리 최소
 - DataFrame 메모리 최적화와 함께하면 최고의 성능 확인 가능

```
preprocessor.dataframe_cleansed.to_parquet(  
    mlpath.df_cleansed_parquet, index=False  
)  
preprocessor.dataframe_cleansed = pandas.read_parquet(mlpath.df_cleansed_parquet)
```

Q&A and Break Time

질의응답 및 휴식시간 (5분)



알쓸신기 2부

- 1) XAI
(LIME VS SHAP)
- 2) Data Centric VS Model Centric
- 3) MLOps





XAI/

Explainable AI

XAI란?

- 설명가능 인공지능(Explainable AI, XAI)은 판단에 대한 이유를 사람이 이해할 수 있는 방식으로 제시하는 인공지능을 일컫는다.
- 특정한 판단에 대해 알고리즘의 설계자조차도 그 이유를 설명할 수 없는 '블랙 박스' 인공지능과 대비되는 개념이다.
- 불확실성을 해소하여 인공지능에 대한 신뢰성을 높일 수 있게 된다.




XAI


Explainable AI

XAI란?

AI



XAI





XAI


Explainable AI

LIME


LIME (Local Interpretable Model-agnostic Descriptions)는 예측 주변에서 해석 가능한 모델을 학습하여 해석 가능하고 충실한 방식으로 분류기의 예측을 설명하는 새로운 설명 기술

Two class case, text


Negative (blue) words indicate atheism, while positive (orange) words indicate christian. The way to interpret the weights by applying them to the prediction probabilities. For example, if we remove the words Host and NNTP from the document, we expect the classifier to predict atheism with probability 0.58 - 0.14 - 0.11 = 0.31.



Multiclass case



Tabular data






XAI

Explainable AI

LIME



<https://github.com/marcotcr/lime>




XAI

Explainable AI

SHAP

SHAP (SHapley Additive exPlanations의 약자)는 기계 학습 합리성에서 최첨단 일 가능성이 높습니다. 이 계산은 Lundberg와 Lee에 의해 2017 년에 처음 배포되었으며 사전 계산의 수율을 계산하는 훌륭한 방법







XAI

Explainable AI

SHAP



<https://github.com/slundberg/shap>



Model-centric AI VS Data-centric AI

앤드류 응 교수님 강의 2021.03.24

DeepLearning.AI

A CHAT WITH ANDREW

MLOps: From Model-centric to Data-centric AI

Wed, MARCH 24
10 to 11am PT
RSVP: mlops0324.eventbrite.com

ANDREW NG

<https://youtu.be/06-AZXmwhJo>





Model-centric AI VS Data-centric AI

내용 비교

Takeaways: Data-centric AI

MLOps' most important task is to make high quality data available through all stages of the ML project lifecycle.



AI system = Code + Data

Model-centric AI

How can you change the model (code) to improve performance?

Data-centric AI

How can you systematically change your data (inputs x or labels y) to improve performance?

Important frontier: MLOps tools to make data-centric AI an efficient and systematic process.



Model-centric AI VS Data-centric AI

성능 비교

	Steel defect detection	Solar panel	Surface inspection
Baseline	76.2%	75.68%	85.05%
Model-centric	+0% (76.2%)	+0.04% (75.72%)	+0% (85.05%)
Data-centric	+16.9% (93.1%)	+3.06% (78.74%)	+0.4% (85.45%)



테슬라 데이터 관리 / 컴퓨터 비전 for Autonomous Driving

[테슬라가 데이터를 다루는 방법](#)

[테슬라 CVPR 2021 분석 - 컴퓨터비전시스템 / 지도학습 / 자동-라벨링 데이터셋 / 슈퍼컴퓨터 / 그림자모드 / 트랜스포머](#)


[테슬라 AI 데이 정리 PART1 - 자율주행 / 트랜스포머 / 예측 / 캘리브레이션 / 프로젝션 / 멀티카메라 네트워크 / 비디오모듈 / Spatial RNN](#)

[테슬라 AI 데이 정리 PART2 - 자율주행 / Planning / 벡터공간 / 라벨링방법/ 오토라벨링 파이프라인 / 3D 포인트 클라우드 / 시뮬레이션](#)



MLOps란?

- 프로덕션에서 기계 학습 모델을 안정적이고 효율적으로 배포하고 유지하는 것을 목표로하는 일련의 프로세스
- "머신러닝"과 소프트웨어 분야에서 DevOps의 지속적인 개발 관행의 합성어





MLOps on GCP

Google의 MLOps

MLOps 수준 0: 수동 프로세스

많은 팀에는 최첨단 모델을 빌드할 수 있는 데이터 과학자와 ML 연구원이 있지만, ML 모델을 빌드하고 배포하는 과정은 완전히 수동으로 이루어집니다. 이는 콘텐츠 성숙도의 기본 수준 또는 수준 0으로 간주됩니다. 다음 다이어그램은 이 프로세스의 워크플로를 보여줍니다.




그림 2. 모델을 예측 서비스로 제공하기 위한 수동 ML 단계



MLOps 수준 1: ML 파이프라인 자동화

다음 그림은 CT용 자동화된 ML 파이프라인을 도식화하여 보여줍니다.




그림 3. CT용 ML 파이프라인 자동화



MLOps on GCP

Google의 MLOps

MLOps 수준 2: CI/CD 파이프라인 자동화

프로덕션 단계에서 파이프라인을 빠르고 안정적이게 업데이트하려면 강력한 자동화된 CI/CD 시스템이 필요합니다. 이 자동화된 CI/CD 시스템을 사용하면 데이터 과학자가 특성 추출, 모델 아키텍처, 초매개변수에 대한 새로운 아이디어를 빠르게 실험할 수 있습니다. 데이터 과학자는 이러한 아이디어를 구현하고 새 파이프라인 구성요소를 대상 환경에 자동으로 빌드, 테스트, 배포할 수 있습니다.

다음 다이어그램은 자동화된 ML 파이프라인 설정과 자동화된 CI/CD 루틴의 특성을 가진 CI/CD를 사용하여 ML 파이프라인을 구현하는 방법을 보여줍니다.





그림 4. CI/CD 및 자동화된 ML 파이프라인



MLOps on AWS


Amazon의 MLOps





MLOps by Nvidia

Nvidia의 MLOps



<https://blogs.nvidia.co.kr/2020/09/11/what-is-mlops/>



실리콘밸리의 MLOps (2021.10.14 블로그 링크)

<https://velog.io/@thousanee/%EC%8B%A4%EB%A6%AC%EC%BD%98%EB%B0%B8%EB%A6%AC%EC%9D%98-MLOps>





국내 *mlops* 적용 기업 사례 : 당근마켓

Google

국내 mlops 적용 기업 사례 당근마켓

X | | | |

검색결과 약 4,050개 (0.35초)

검색

뉴스

이미지

동영상

지도

더보기

도구

https://www.facebook.com > TensorFlowKR > permalink

당근마켓 서비스에 머신러닝을 적용하면서 데이터 관점이 ...

"MLOps와 높은 진입 장벽"이라는 주제로 ML Google Developers Expert이신 박찬성(Park Chansung)님을 모시고 온라인 공개 세미나를 개최할 예정입니다. 머신러닝 ...

https://m.facebook.com > Facebook Groups > MLOps KR

MLOps KR | 다음주 수요일(23일) 당근마켓 채용 오픈 세션에 ML팀도 ...

당근마켓 머신러닝 파이프라인 소개도 간단히 드릴 것 같아요 ! ... 따른따관한 성운님의 유튜브 그리고 제가 회사에서 발행하는 MLOps Insight 공유드려요.

https://aws.amazon.com > blogs > korea > aws-gameday... ▾

아시아 지역 AWS AI/ML GameDay에서 우승한 자랑스런 한국 ...

2021. 12. 17. — 이전에 당근마켓에서 참석했던 상반기 AWS GameDay 사례를 알고 있었기 때문 에, AWS 상에서 겪어볼 수 있는 다양한 상황을 경험해 볼 수 있을 거라 기대 ...

https://cloud.google.com > customers > daangn-market ▾

TensorFlow 인프라로 커뮤니티 게시물 운영 효율성 극대화

당근마켓은 Google Cloud Platform을 통해 빅데이터와 머신러닝 기반의 데이터 분석 ... 당근마켓 은 이 두 부분에 TensorFlow 모델을 적용하면서 일어나는 게시물을 ...

누락된 검색어: 국내 mlops

https://it.donga.com > ... ▾

[스타트업인] 개발만큼 중요한 것은 '고객과의 소통', 당근마켓 ...

2022. 5. 6. — 신지영 리더(이하 신 리더): 당근마켓 서비스 운영실을 총괄하고 있다. 당근마켓은 고객선택을 외부에 두지 않고, 자체적 고객지원회사 '당근서비스'를 ...

누락된 검색어: mlops | 다음 정보가 포함되어야 합니다. mlops

https://www.nextunicorn.kr > newsroom

인공지능 개발자들을 위한 제1회 MLOps KR 커뮤니티 행사 ...

글로벌 AI 리더 엔드류 올 교수 비롯, 전 세계 AI 전문가들 'ML올스' 중요성에 입 모아 - 슈퍼브레이 아이, 쏘카, 쿠팡 등 국내 기업 후원 및 연사로 나서 - 6월 5 ...

누락된 검색어: 사례 당근 마켓

https://www.ciokorea.com > news ▾

최형광 칼럼 | 플랫폼과 아웃사이드 인 - CIO Korea

2021. 5. 21. — 인사이드 아웃(Inside out)이란 기업의 역량을 최대화하며 그 제품과 서비스 ... 대 표적 사례는 당근마켓이며 소비자 시장 중심으로 진행되는 집로스, ...

<https://cloud.google.com/customers/daangn-market?hl=ko>

Q&A

질의응답 (5분)





다음주는 최종 프로젝트 발표날!

Contents for Next Week

프로젝트 제출물 리스트



프로젝트 보고서 Word
(PDF로 제출)

[머신러닝입문] 1팀 프로젝트 보고서.pdf



소스코드
(ipynb file & Data File)

[머신러닝입문] 1팀 프로젝트 소스코드.ipynb

[머신러닝입문] 1팀 프로젝트 데이터.csv



발표자료 PPT
(PDF로 제출)

[머신러닝입문] 1팀 프로젝트 발표자료.pdf



끝. 감사합니다.

수업 듣느라 수고하셨습니다.

